

챕터 6. 연차도 규정도 한번에. ReAct Agent와 Tool Calling

이번 챕터가 끝나면

- **@tool** 데코레이터로 DB 조회, 문서 검색을 에이전트가 선택할 수 있는 도구로 감쌉니다
- **ReAct 패턴**(Reason, Act, Observe 반복)으로 복잡한 질문을 단계적으로 해결합니다
- 에이전트가 **어떤 도구를 호출했는지**로 질문 유형(정형·비정형·복합)을 사후 판정합니다
- "A 사원 연차 며칠? 그리고 신청 절차도 알려줘" 같은 복합 질문에 한 번의 답으로 응답합니다

준비하기. 실습 시작 전 한 번만 설정

1. 실습 폴더 이동

터미널 폴더 이동

```
cd rag-start/ex06
```

파일 구조는 다음과 같습니다.

ex06 디렉토리

```

ex06/
├── run.py
├── src/
│   ├── mcp_tools.py      # [실습] @tool 4개
│   ├── agent.py          # [실습] ReAct 에이전트 조립
│   ├── llm_factory.py    # [참고] Ollama/OpenAI 분기
│   ├── db_helper.py      # [참고] PostgreSQL + ChromaDB 헬퍼
│   └── agent_helpers.py  # [참고] 결과 파싱 유틸
├── app/
│   ├── main.py           # [참고] FastAPI 진입점
│   ├── chat_api.py       # [설명] 에이전트/RAG 모드 선택 API
│   ├── admin_views.py    # [참고] 관리자 대시보드 라우터
│   └── database.py        # [참고] PostgreSQL 연결
├── templates/            # [참고] 채팅 UI + 관리자 대시보드
└── static/               # [참고] UI 스타일
    
```

2. 실습 환경 구축

터미널 환경 구성. macOS / Linux

```

cd ex06
cp .env.example .env
python3.12 -m venv .venv
source .venv/bin/activate
docker compose up -d
ollama pull llama3.1:8b
pip install -r requirements.txt
    
```

터미널 환경 구성. Windows

```

cd ex06
copy .env.example .env
py -3.12 -m venv .venv
.venv\Scripts\activate
docker compose up -d
ollama pull llama3.1:8b
pip install -r requirements.txt
    
```

이전 챗터 Docker가 떠 있으면 포트 충돌

챗터 2의 Docker가 실행 중이라면 `cd ex02 && docker compose down`으로 먼저 종료해 주세요. 같은 포트(5432)를 씁니다.

3. 사용할 라이브러리

패키지	역할
<code>langchain</code>	체인·에이전트 프레임워크
<code>langchain-ollama</code>	Ollama LLM 연결 (Tool Calling 지원 모델 필수)
<code>langchain-chroma</code> · <code>chromadb</code>	벡터 DB 래퍼·저장소
<code>psycopg2-binary</code>	PostgreSQL 드라이버
<code>fastapi</code> · <code>uvicorn</code>	웹 API 서버

Tool Calling 지원 모델을 써야 합니다

모든 Ollama 모델이 Tool Calling을 지원하지는 않습니다. `llama3.1:8b`는 추론과 Tool Calling을 둘 다 안정적으로 해내서 이 챗터에 적합합니다 (16GB RAM에서 무리 없이 돌고 한국어 품질도 무난). 반면 `deepseek-r1`은 **추론에 특화된 대신** Tool Calling이 지원되지 않습니다. 에이전트가 도구를 스스로 호출해야 하는 이 챗터에서는 쓸 수 없으니 `llama3.1:8b`로 교체해 주세요.

`.env` 핵심 상수입니다. 챗터 5에서 쓰던 `.env`와 비교해 LLM 모델이 바뀌고, DB 접속 정보가 추가됩니다.

상수	기본값	역할
<code>LLM_PROVIDER</code>	<code>ollama</code>	LLM 제공자 (<code>ollama</code> 또는 <code>openai</code>). 이 챗터는 Tool Calling 지원 모델만 가능
<code>OLLAMA_MODEL</code>	<code>llama3.1:8b</code>	챗터 5의 <code>deepseek-r1:8b</code> 에서 변경. Tool Calling 지원
<code>OPENAI_MODEL</code>	<code>gpt-4o-mini</code>	OpenAI 쓸 때 권장. Ollama보다 Tool Calling이 안정적
<code>POSTGRES_*</code>	<code>rag_db</code> / <code>rag_user</code> / ...	챗터 2에서 띄운 DB 접속 정보
<code>CHROMA_PERSIST_DIR</code>	<code>./data/chroma_db</code>	ex06 자체 벡터 DB. 첫 실행 시 <code>data/docs/</code> 로부터 자동 구축
<code>RETRIEVER_TOP_K</code>	<code>3</code>	<code>search_documents</code> 도구가 가져올 청크 수

4. 실습 순서

1. `src/mcp_tools.py` . @tool 4개 (연차, 매출, 직원, 문서)
2. `src/agent.py` . ReAct 에이전트 조립 + 사후 분류
3. `python run.py` . 서버 실행 후 `http://localhost:8000/chat` 에서 복합 질문 테스트

6.1 RAG가 답 못 하는 질문

 그림 6-1. 서가뿐 아니라 장부실 열쇠까지 쥔 사서. 질문 하나에 두 자료함을 모두 살피는 통합 에이전트

목요일 오후 4시. 창밖이 노랗게 물들고 있었습니다. 키보드 소리가 드문드문 울리는 사무실이었습니다.

챗터 5에서 채팅 UI를 띄워 두고 동료들이 한 번씩 써 보게 했습니다. 첫 반응은 나쁘지 않았습니다. 그런데 얼마 후 다른 동료가 노트북을 들고 책상 앞까지 왔습니다.

동료 : "이게 그 AI 비서예요? 한번 써봐도 되죠?"

오픈이 : "당연하죠. 뭐든 물어보세요."

동료가 채팅창에 입력을 시작했습니다.

동료 : "A 사원 남은 연차는? 그리고 연차 신청 절차 알려줘요."

잠시 후 돌아온 답변은 "해당 직원에 대한 정보를 찾지 못했습니다"였습니다.

오픈이는 당황해서 질문을 바꿔 넣어 봤습니다. "이번 달 매출 합계." 같은 대답. "직원 목록 보여줘." 역시 같은 대답.

동료 : "직원 이름도 모르는 AI 비서예요?"

동료가 돌아간 자리에는 노트북 화면 위의 에러 문구만 남았습니다.

사서는 여전히 서가만 뒤지고 있었다. 챗터 2에서 만들어 둔 장부실이 옆방에 있는데, 그쪽 문을 열 줄 모른다.

옆자리 팀장이 모니터를 흘끔 보고 한 마디 던졌습니다.

팀장 : "사서한테 책만 찾게 하지 말고, 장부도 꺼내게 해봐요."

지금의 사서는 서가에서 규정집만 꺼내 줍니다. 하지만 'A 사원'은 서가 어디에도 없습니다. 직원 연차 정보는 책이 아니라 **PostgreSQL 장부**에 적혀 있습니다. 장부실을 여는 법을 배우지 못한 사서는 "없어요"만 반복했습니다.

6.2 정형 데이터와 비정형 데이터

지금 만들어 둔 것을 정리하면:

- **챗터 2**: 직원, 연차, 매출을 PostgreSQL에 저장하는 API
- **챗터 4~5**: 사내 문서를 벡터 DB에 넣고 검색, 답변하는 RAG 엔진

둘이 따로 놓고 있습니다. AI 비서는 RAG만 쓸 줄 알지 DB에 접근하는 법을 모릅니다.

질문	경로
"A 사원 연차 몇 개?"	PostgreSQL 조회 (정형)
"연차 신청 절차?"	취업규칙 문서 검색 (비정형)
"A 사원 연차 + 신청 절차?"	둘 다 (복합)

진짜 비서가 되려면 이 둘을 상황에 맞게 고르거나, 필요하면 동시에 써야 합니다.

6.3 사서가 두 자료함을 연다

팀장이 말한 "장부까지 꺼내는 사서"를 그려 보겠습니다. 지금까지 서가 하나만 맡던 사서에게 옆방 장부실 열쇠를 새로 쥐여 주는 장면입니다.

이용자 : "A 사원 연차 며칠 남았어요?"

사서 : (장부실로 가서 연차 장부를 펼친다) "3일 남았습니다."

며칠 후 복잡한 질문.

이용자 : "A 사원 연차 며칠 남았고, 신청 절차도 알려주세요."

사서 : (장부실에서 연차를 확인한 뒤 서가로 가서 규정집까지 찾아온다) "3일 남았고, 규정은 이렇습니다..."

한 명의 사서가 자료의 성격을 보고 **장부실과 서가를 스스로 오갑니다**. 바깥에 안내 직원을 따로 두고 "너는 장부실, 너는 서가" 하고 미리 나누지 않습니다. 사서가 질문을 보자마자 필요한 자료함을 직접 엽니다.

 그림 6-2. 어느 자료함을 열지는 사서가 알아서 판단합니다.

AI 비서도 같은 구조가 됩니다. 한 명의 **에이전트**가 질문을 보고 장부 도구(`leave_balance` 등)를 열지, 문서 도구(`search_documents`)를 열지, 둘 다 열지 판단합니다. 판단 주체는 에이전트 속 LLM 자신이지, 바깥의 분류기가 아닙니다. 이번 챕터의 **통합 에이전트**가 이 "만능 사서"입니다.

6.3.1 파이프라인에서 에이전트로 (챗터 5 엔진은 유지됩니다)

챗터 5에서 만든 건 **고정된 파이프라인**이었습니다. 질문이 들어오면 언제나 같은 순서로 흐릅니다. Retriever로 문서 조각을 가져오고, Prompt로 감싸고, LLM에 보내고, 답을 돌려받죠. 입력 질문이 "휴가 규정"이든 "A 사원 연차"든 똑같은 경로를 탑니다. 문제는 그 경로 중간에 **PostgreSQL 장부를 들여다보는 단계가 없다는** 점입니다. 체인을 새로 짤다 해도 "이 질문에는 DB를 볼까 문서만 볼까?"를 **실시간으로 판단할 자리가 없습니다**. 고정 파이프는 분기가 약합니다.

에이전트는 다릅니다. 질문을 받으면 LLM이 먼저 "지금 어느 자료함을 열어야 하지?"를 스스로 판단합니다. 결과를 보고 "충분한가, 아니면 한 곳 더?"를 다시 판단합니다. 이 **생각(Reason) → 행동(Act) → 관찰(Observe)** 루프가 **ReAct 패턴**입니다. 경로가 질문마다 달라지죠.

그림 6-3. LCEL 체인 vs ReAct 에이전트

항목	LCEL 체인 (챗터 5)	ReAct 에이전트 (이 챗터)
흐름	고정 순서. Retriever → Prompt → LLM	동적. 질문을 보고 매 턴 경로 결정
도구 선택	없음 (문서 검색만)	LLM이 스스로 고름
분기	파이프를 짤 때 하드코딩	런타임에 판단
적합한 질문	순수 문서 Q&A	정형·비정형·복합을 한 창구로


"그럼 파이프라인에서 Tool Calling만 붙이면 되지 않나?" 사실 LCEL에서도

`llm.bind_tools([...])` 로 도구를 묶을 수 있고, LLM이 어떤 도구를 호출할지 고르는 것까진 됩니다. 여기까지는 체인 한 번으로 충분하죠. 진짜 문제는 **루프**입니다. 도구가 답을 내놓으면 LLM은 그걸 보고 "충분한가? 한 번 더?"를 다시 판단해야 합니다. LCEL 체인은 입력 → 출력 한 번 흐르고 끝나는 구조라 이 **재판단**을 자동으로 돌리지 않습니다. 필요할 때마다 수동으로 while 루프를 짜야 하죠.

ReAct 에이전트(AgentExecutor)는 그 루프를 **한 줄 호출로 자동화**합니다. 도구 선택 → 실행 → 결과 관찰 → 다음 판단 → (끝까지) 를 AgentExecutor가 알아서 돌립니다. 복합 질문("A 사원 연차 + 신청 절차")처럼 도구를 두세 번 연달아 써야 할 때 이 자동 루프가 빛을 발합니다.

그림으로 보면 파이프라인이 어디에 박혀 있는지 한눈에 보입니다. 바깥을 **ReAct 루프**가 감싸고, 그 안에서 에이전트가 도구 4개를 골라 씁니다. 그중 `search_documents` 도구의 속을 열어 보면 챗터 5에서 만든 **LCEL 파이프라인이 그대로** 들어 있습니다.

그림 6-4. ReAct 에이전트 안의 파이프라인. 챗터 5 엔진은 버려지지 않고 도구 하나로 감싸져 들어옵니다



정리하면 세 층입니다. **바깥층**은 ReAct 루프가 질문마다 경로를 정합니다. **중간층**은 도구 4개 중 어떤 걸 쓸지 선택하는 자리입니다. **안쪽층**이 `search_documents` 안에서 돌아가는 챕터 5의 LCEL 파이프라인이고요. 복합 질문이 들어오면 바깥 루프가 두 번 돕니다. 먼저 `leave_balance` 로 SQL 한 번, 다음 턴에 `search_documents` 안의 파이프라인이 문서 한 번. 두 결과를 합쳐 최종 답변을 만듭니다.

여기서 중요한 건 **챕터 5 엔진을 버리지 않는다**는 점입니다. `rag_chain.py` 의 LCEL 파이프라인은 그대로 보존됩니다. 다만 이번 챕터에서는 그 엔진을 **에이전트의 도구 하나**(`search_documents`)로 감싸 넣고, 옆에 `leave_balance` · `sales_sum` · `list_employees` 세 도구를 나란히 둡니다. 엔진을 버리는 게 아니라 **더 큰 판단 구조(에이전트) 아래에 배치**하는 것입니다. 다음 챕터 7, 10도 이 에이전트 구조를 그대로 이어받습니다.

다음 절부터 이 사서의 손에 들릴 **도구**를 하나씩 만들어 보겠습니다.

6.4 MCP Tools: @tool 데코레이터

사서가 손에 들 **자료함(도구)** 을 네 개 준비합니다. 앞의 세 개는 장부실, 마지막 하나는 서가에 있습니다.

도구	역할	데이터 원천
<code>leave_balance</code>	특정 직원 연차 잔여일	PostgreSQL <code>employees</code> + <code>leave_balance</code>
<code>sales_sum</code>	부서·기간별 매출 합계	PostgreSQL <code>sales</code>
<code>list_employees</code>	이름·부서로 직원 목록	PostgreSQL <code>employees</code>
<code>search_documents</code>	문서 기반 질문 답변	ChromaDB (챗터 4~5 파이프라인)

6.4.1 @tool vs MCP — 도구 호출의 두 가지 방식

AI 에이전트가 외부 기능을 호출하는 방법은 크게 두 가지가 있습니다. 하나는 Anthropic이 만든 **MCP(Model Context Protocol)** 입니다. 도구를 별도 서버로 분리하고 표준 메시지 규격으로 통신하는 방식이라 어떤 프레임워크에서든 같은 도구를 재사용할 수 있습니다. 다른 하나는 LangChain의 `@tool` 데코레이터입니다. 같은 프로세스 안에서 함수를 직접 호출하니 설정이 간단합니다.



그림 6-3. LangChain `@tool` 데코레이터와 MCP 방식의 도구 호출 비교. 전자는 에이전트와 함수가 한 프로세스, 후자는 MCP 서버로 분리된 별도 프로세스입니다

MCP 쪽 화살표에 적힌 `stdio · HTTP` 는 에이전트와 MCP 서버가 대화할 때 쓰는 통신 규격입니다. 두 프로세스가 따로 떼 있으니 직접 함수 호출은 못 하고, 중간에 약속된 메시지 형식이 필요합니다. 같은 컴퓨터 안에서는 **stdio**(표준 입출력 스트림)로, 원격 서버는 **HTTP**로 메시지를 주고받습니다. Claude Desktop·Cursor·IDE 에이전트 같은 여러 앱이 같은 MCP 서버에 붙을 수 있는 이유도 이 표준 규격 덕분입니다. 반대로 `@tool` 은 파이썬 함수를 그대로 호출하므로 이런 프로토콜이 필요 없습니다.

핵심 개념은 같습니다. "AI가 함수의 이름과 설명을 보고 스스로 호출한다." 이 책에서는 `@tool` 로 원리를 익혀 보겠습니다. 원리를 이해하면 MCP로 확장하는 건 어렵지 않습니다.

각 도구 함수에 `@tool` 데코레이터와 독스트링(설명)을 붙여두면 LangChain이 도구의 이름과 설명, 파라미터를 자동으로 읽어옵니다. 에이전트는 이 정보를 보고 "이 질문에는 어떤 도구가 맞지?"를 판단합니다. 이처럼 LLM이 상황에 맞는 도구를 스스로 골라서 호출하는 기능을 **도구 호출(Tool Calling)** 이라고 합니다. 모든 LLM이 지원하는 건 아니라서 OpenAI의 `gpt-4o-mini` 나 Ollama의 `llama3.1:8b` 처럼 Tool Calling을 지원하는 모델을 골라야 합니다.

`@tool` 데코레이터. 파이썬 `@decorator` 문법은 함수 정의 위에 붙여 **함수를 다른 함수로 감싸 주는** 표시입니다. `@tool` 은 LangChain이 제공하는 데코레이터로, 일반 함수를 LLM이 호출 가능한 `Tool` 객체로 자동 변환해 줍니다. 함수 이름·인자 타입·반환 타입·docstring을 읽어 스키마를 만들고, 에이전트에게 "이 도구는 `(emp_no: str) -> dict` 를 받습니다"처럼 구조화된 정보로 전달합니다. 직접 `Tool(name=..., func=..., description=...)` 를 수동 조립하지 않아도 됩니다.

docstring. 함수 본문 첫 줄에 놓이는 삼중 따옴표 문자열(`"""..."""`)입니다. 원래는 사람 개발자용 설명이지만, `@tool` 에서는 **LLM이 도구를 고를 때 읽는 사용 설명서**로 쓰입니다. "언제 이 도구를 쓰는가"를 명확히 적어야 에이전트가 올바르게 선택합니다. 예: `"""주어진 사번의 연차 잔여일수를 반환합니다."""`

6.4.2 도구 구현하기

`src/mcp_tools.py` 에 네 개의 함수 TODO가 있습니다. 각 TODO의 `pass` 를 지우고 `@tool` 과 docstring, 인자를 채웁니다.

실습 2 ex06/src/mcp_tools.py. @tool 데코레이터

```
from src.db_helper import run_query, get_vectorstore, DB_ERROR_MSG

@tool
def leave_balance(emp_no: str) → dict:
    """직원의 연차 잔여 일수를 조회한다."""
    # TODO: leave_balance - 사번으로 연차 조회

    # 1. DB 조회 (employees + leave_balance 조인)
    rows = run_query(
        """SELECT e.name, l.total_days, l.used_days,
               (l.total_days - l.used_days) AS remaining_days
        FROM employees e
        LEFT JOIN leave_balance l ON e.emp_no = l.emp_no
        WHERE e.emp_no = %s""",
        (emp_no,)
    )

    # 2. 결과 있으면 반환, 없으면 에러
    return rows[0] if rows else {"error": DB_ERROR_MSG}

@tool
def search_documents(query: str, k: int = 3) → dict:
    """사내 문서에서 관련 내용을 벡터 검색한다."""
    # TODO: search_documents - ChromaDB로 관련 청크 검색

    # 1. ChromaDB 컬렉션 가져오기
    collection = get_vectorstore()

    # 2. 벡터 검색 수행
    results = collection.query(query_texts=[query], n_results=k)

    # 3. content / source 형태로 가공
    docs = [
        {"content": doc, "source": results["metadatas"][0][i].get("source", "unknown")}
        for i, doc in enumerate(results["documents"][0])
    ]
    return {"results": docs, "total_found": len(docs)}
```

`run_query` · `get_vectorstore` 는 `src/db_helper.py` 의 보조 함수로, PostgreSQL 커넥션과 ChromaDB 컬렉션을 감싼 헬퍼입니다. 직접 작성하지 않고 import만 합니다.

나머지 두 개는 DB 조회의 다른 변형입니다. `sales_sum` 은 집계 쿼리(SUM + GROUP BY), `list_employees` 는 동적 WHERE 조립(부서·이름 필터).

실습 2 ex06/src/mcp_tools.py. 집계·동적 필터

@tool

```
def sales_sum(dept: str = "", start_date: str = "", end_date: str = "") → dict:
    """부서별 또는 전체 매출 합계를 조회한다."""
    # TODO: sales_sum - 기간·부서 필터로 매출 집계

    # 1. 파라미터 기본값 처리
    start = start_date or "2024-11-01"
    end = end_date or "2024-12-31"

    # 2. DB 조회 (부서 필터 적용)
    dept_filter = f"AND e.department LIKE '%{dept}%'" if dept else ""
    rows = run_query(
        f"""SELECT SUM(s.amount) AS total_amount
            FROM sales s JOIN employees e ON s.emp_no = e.emp_no
            WHERE s.sale_date BETWEEN %s AND %s {dept_filter}""",
        (start, end),
    )

    # 3. 결과 가공해서 반환
    return {"total_amount": rows[0]["total_amount"] if rows else 0,
            "period": f"{start} ~ {end}"}
```

@tool

```
def list_employees(dept: str = "", name: str = "") → dict:
    """직원 목록을 조회한다. 부서·이름으로 필터 가능."""
    # TODO: list_employees - WHERE 조건을 동적으로 조립

    # 1. 조건 조립 (부서/이름 필터)
    conditions, params = [], []
    if dept:
        conditions.append("department LIKE %s"); params.append(f"%{dept}%")
    if name:
        conditions.append("name LIKE %s"); params.append(f"%{name}%")

    # 2. SQL 문자열 완성 + 실행
    sql = "SELECT emp_no, name, department, position, hire_date FROM employees"
    if conditions:
        sql += " WHERE " + " AND ".join(conditions)
    rows = run_query(sql + " ORDER BY name", tuple(params))

    # 3. 결과 반환
    return {"employees": rows, "count": len(rows)}
```

도구의 docstring이 **LLM의 판단 근거**가 되므로 "이 도구는 언제 써야 하는가"를 명확히 써 주세요. 설명이 불명확하면 에이전트가 엉뚱한 도구를 고릅니다. AI 비서에게 각 도구가 무슨 일을 하는지 제대로 알려줘야 제대로 골라 쓰는 것과 마찬가지입니다.

MCP Tools? Tool? 이 책에서는 LangChain `@tool` 로 만든 함수를 포괄해 **MCP Tools**라고 부릅니다. Model Context Protocol의 의미를 확장해 "AI가 호출 가능한 도구 계층"이라는 개념적 명칭으로 씁니다. 구현 수단은 LangChain의 Tool Calling이지만, 같은 역할(도구 호출 계층)을 MCP 서버로도 구현할 수 있습니다.

6.5 ReAct 패턴 & 에이전트 조립

챕터 1에서 "리프레시 데이 몇 번 남았어?"라는 질문을 던졌습니다. LLM이 규정을 읽고 "매월 1회 → 6개월이면 6번 → 2번 썼으면 4번"까지 스스로 계산해 냈죠. 생각의 고리가 사슬처럼 이어지는 **사슬 추론 (Chain-of-Thought)** 입니다. ReAct는 여기에 **도구 호출**을 끼워 넣은 확장판입니다.

챕터 1 사슬 추론	챕터 6 ReAct
하는 일: 문서를 읽고 단계별 계산 반복: 머릿속에서 1회 예시: "6개월이면 6번, 2번 쓰면 4번" 핵심: 읽고 생각	하는 일: 도구를 고르고 호출하고 결과 확인 반복: Reason→Act→Observe 여러 바퀴 예시: "DB 조회 → 결과 보고 → 문서 검색" 핵심: 생각하고 행동

"생각만 하는" 사슬 추론에서 "생각하고 행동하고 결과를 보는" ReAct로 진화합니다.

사서는 복합 질문을 한 번에 풀지 않습니다. 장부실과 서가 사이를 왔다 갔다 하면서 자료를 조각조각 모읍니다. 그 왕복의 머릿속 패턴은 이렇습니다.

1. **Reason (추론)**. "연차 잔여일이 먼저 필요하겠네. 그다음 신청 절차."
2. **Act (행동)**. `leave_balance(emp_no="E003")` 호출
3. **Observe (관찰)**. "총 15일, 잔여 8일이 돌아왔군"
4. **Reason**. "이제 신청 절차를 문서에서 찾자"
5. **Act**. `search_documents(query="연차 신청 절차")`

6. **Observe.** "그룹웨어 → 근태관리 → 연차신청"

7. 최종 답변 생성

이 Reason, Act, Observe 반복이 **ReAct 패턴**입니다. LangChain의

`create_tool_calling_agent` + `AgentExecutor` 가 루프를 자동으로 돌려 줍니다.



6.5.1 에이전트 조립하기

`src/agent.py` 에 에이전트 조립 TODO가 있습니다. TODO의 `pass` 를 지우고 아래 코드를 작성합니다. `create_tool_calling_agent` + `AgentExecutor` 로 ReAct 루프를 만듭니다.

실습 3 ex06/src/agent.py. ReAct 에이전트

```
from src.mcp_tools import ALL_TOOLS

SYSTEM_PROMPT = """당신은 사내 HR 및 업무 질문에 답변하는 AI 어시스턴트입니다.
- 정형 데이터(숫자·통계·목록)는 DB 조회 도구를 사용하세요.
- 비정형 질문(절차·정책·설명)은 search_documents를 사용하세요.
- 복합 질문은 두 종류의 도구를 모두 사용하세요."""

# TODO: agent 조립 - 도구 + LLM + 프롬프트

# 1. 프롬프트 구성 (system + history + input + scratchpad)
prompt = ChatPromptTemplate.from_messages([
    ("system", SYSTEM_PROMPT),
    MessagesPlaceholder(variable_name="chat_history", optional=True),
    ("human", "{input}"),
    MessagesPlaceholder(variable_name="agent_scratchpad"),
])

# 2. Tool Calling Agent 생성
agent = create_tool_calling_agent(llm=llm, tools=ALL_TOOLS, prompt=prompt)

# 3. AgentExecutor 래핑 (중간 단계 반환 활성화)
executor = AgentExecutor(
    agent=agent, tools=ALL_TOOLS,
    verbose=False, return_intermediate_steps=True,
    max_iterations=10, handle_parsing_errors=True,
)
```

등장한 LangChain 부품 세 개를 한 줄씩 정리합니다.

부품	역할
<code>create_tool_calling_agent(llm, tools, prompt)</code>	LLM·도구·프롬프트를 묶어 "판단만 하는" 에이전트 코어 생성. 도구 호출 결정까지만 책임짐
<code>AgentExecutor(agent, tools, ...)</code>	에이전트 코어를 받아 ReAct 루프를 실제로 돌리는 실행기. 도구 호출, 결과 주입, 다음 판단 요청을 반복. <code>max_iterations</code> 로 무한 루프 방지
<code>MessagesPlaceholder("agent_scratchpad")</code>	ReAct 루프의 메모장 . 각 Reason·Act·Observe 단계가 여기에 쌓이고, 에이전트가 매 턴 이전 기록을 참고해 다음 결정을 내림

"LLM이 도구를 한 번 고르는 것"과 "복잡한 질문을 풀기 위해 도구를 여러 번 반복 호출하는 것"은 다릅니다. 전자는 `create_tool_calling_agent` 만으로 되지만, 후자는 `AgentExecutor` 가 루프를 돌려야 가능합니다. `agent_scratchpad` 는 그 루프의 기억 창구입니다.

6.6 서버 실행 + 복합 질문 테스트

터미널 서버 실행

```
python run.py
```

브라우저에서 `http://localhost:8000/chat` 을 엽니다. 이번엔 모드 토글이 생겼습니다. **Agent 모드**로 바꾸면 화면 상단에 **정형·비정형·복합** 세 그룹으로 묶인 샘플 질문 버튼이 나타납니다. 하나씩 눌러 에이전트가 어떤 경로로 답변하는지 확인합니다.

질문 유형	예시 버튼	에이전트가 부르는 도구
정형	"김민준 연차 잔여일수 알려줘" · "영업부 11월 매출 합계가 얼마야?" · "개발부 직원 목록 보여줘"	<code>leave_balance</code> · <code>sales_sum</code> · <code>list_employees</code>
비정형	"온보딩 절차가 어떻게 되나요?" · "보안 정책에 대해 설명해줘" · "출장 비용 규정 알려줘"	<code>search_documents</code>
복합	"매출 상위 부서의 위케이션 규정은?" · "정시우 사원의 연차 잔여와 휴가 규정을 설명해주세요"	여러 도구 연쇄 호출

 그림 6-5. 복합 질문 "정시우 사원의 연차 잔여와 휴가 규정을 설명해주세요"에 대한 답변입니다. DB에서 숫자를 꺼내고 문서에서 절차를 찾아 한 답으로 정리합니다

"정시우 사원의 연차 잔여와 휴가 규정을 설명해주세요"라는 복합 질문이 들어왔을 때, 에이전트 머릿속의 사슬 추론은 이렇게 흘러갑니다.

Reason 1: "연차 잔여일은 DB에 있겠지. leave_balance를 호출하자." **Act 1:**

`leave_balance(emp_no="E003")` → **Observe 1:** "총 15일, 사용 7일, 잔여 8일" **Reason 2:**

"잔여일은 알았고, 휴가 규정은 문서에 있겠지." **Act 2:** `search_documents("휴가 규정")` →

Observe 2: "취업규칙 제15조 연차유급휴가..." **Reason 3:** "두 정보 다 모였다. 답변을 만들자."

챕터 1의 사슬 추론은 머릿속에서 한 번에 끝났지만, ReAct는 **도구를 호출하고 결과를 확인하는 행동**이 추론 사이사이에 끼어듭니다. 생각의 고리가 행동으로 이어지고, 행동의 결과가 다음 생각의 입력이 됩니다.

![(../assets/챕터 6/terminal/06_agent-run-real.png) 그림 6-6. `python -m src.agent` 실행 결과입니다. 도구 호출 → 사후 분류 → 최종 답변까지 실제 단계별 로그가 찍힙니다

동료: "이제 진짜 비서 같은데요."

오픈이가 수첩을 꺼냈습니다. 입사 3일 차에 처음 AI 비서를 켜올 때와 지금의 차이를 한 장 안에 적어 두고 싶었습니다.

— 생각 정리 —

1. 정형 질문

- "A 사원 연차 잔여?" 같은 숫자·필드 조회
- DB 도구 하나면 빠르게 답함

2. 비정형 질문

- "연차 신청 절차?" 같은 규정·매뉴얼 조회
- 문서 검색으로 정확한 근거 제공

3. 복합 질문

- 정형 + 비정형이 한 문장에 섞인 경우
- ReAct로 도구를 연쇄 호출해 한 번에 답함

→ 에이전트가 "어느 자료함을 열지" 스스로 판단

6.7 전체 구성도에서 챕터 6의 자리

전체 구성도. 짙은 박스가 챕터 6 범위

사내 직원 · 관리자

챕터 2

대시보드

FastAPI

REST API · 관리자 웹

챕터 6

오케스트레이션

오늘 만든 부분

Tool Calling Agent

ReAct 패턴 · 사후 분류

오늘 만든 부분

MCP Tools

DB 조회 · 문서 검색

챕터 5

검색 (실시간)

LCEL Chain

검색기 → 프롬프트 → LLM

챕터 4

파싱·벡터화 (오프라인)

챕터 3 문서 규칙

PDF·Word·Excel·HWP

Doc Pipeline

파싱·청킹·임베딩

ChromaDB

벡터 저장소

챕터 2

데이터

PostgreSQL

직원·연차·매출

Ollama LLM (외부)

오늘 채운 건 **Tool Calling Agent**와 **MCP Tools** 두 박스입니다. 위쪽 사용자 입력부터 아래쪽 데이터, 문서 저장소까지 전 구간이 하나로 연결됐습니다. 챕터 7에서는 이 에이전트를 실제 운영에 올렸을 때 생기는 속도, 비용 문제를 ResponseCache와 TokenTracker로 잡습니다.

종료합니다

`Ctrl + C` 로 서버를 종료합니다. Docker 컨테이너는 챕터 7에서도 같은 PostgreSQL·ChromaDB를 쓰므로 그대로 두세요.

용어 정리

본문 속 표현	진짜 용어	정식 정의
"만능 사서"	에이전트 (Agent)	질문을 받아 스스로 판단하고 도구를 선택·실행해 답변을 만드는 자율 프로그램
"자료함" (장부실 · 서가)	도구 (Tool)	<code>@tool</code> 데코레이터로 감싼 함수. 에이전트가 선택 실행하는 원자 작업 단위
"호출한 도구로 라벨 붙이기"	사후 분류 (Post-hoc)	에이전트가 실행 후 실제 호출한 도구 종류로 질문 유형 (structured-unstructured-hybrid) 을 확정하는 방식
"생각 → 행동 → 관찰"	ReAct 패턴	Reason·Act·Observe 반복으로 복잡 질문을 단계적 해결하는 에이전트 전략
"반복 실행기"	AgentExecutor	ReAct 루프를 돌리고 도구 호출을 관리하는 LangChain 컴포넌트

이것만은 기억하자

- **문서 검색만으론 진짜 비서가 될 수 없습니다.** 정형 데이터(DB)와 비정형 데이터(문서)를 한 에이전트에서 통합해야 "연차 며칠?", "신청 절차?", "둘 다"를 모두 답할 수 있습니다.
- **분류는 사전 판정이 아니라 사후 분류입니다.** 에이전트가 자율적으로 도구를 고르고, 실제 호출된 도구 종류로 질문 유형이 확정됩니다. 두 도구가 모두 호출되면 그게 바로 복합(hybrid)입니다.
- **ReAct 루프가 복합 질문을 푼다.** Reason, Act, Observe 반복으로 에이전트가 도구를 여러 번 호출하고 결과를 묶어 한 답으로 돌려 줍니다. 챕터 7에서는 이 에이전트의 속도, 비용을 잡는 운영 기술을 다룹니다.