

머릿말

RAG 관련 자료를 처음 찾아보셨을 때, 혹시 이런 느낌 아니었나요? "LangChain 공식 문서는 있는데... 이걸 어디서 어떻게 시작하지?"

"예제는 따라 했는데, 막상 내 문서를 넣으면 검색이 왜 이렇게 안 되지?" "기본 RAG는 만들었는데, 정확도를 올리려면 뭘 건드려야 하지?"

이 책은 그 질문들에서 시작했습니다.

이 책에서 만드는 것

처음부터 끝까지 하나의 프로젝트를 만듭니다.

사내 AI 비서 **ConnectHR**입니다. 직원 정보를 조회하고, 인사 규정 문서를 검색하고, 두 가지를 한 번에 답해주는 시스템입니다. CH01에서 LLM 환각을 체험하고, CH11에서 튜닝을 모두 적용한 완성 에이전트로 마무리합니다.

조각난 예제가 아닙니다. 처음부터 끝까지, 하나의 프로젝트입니다.

다른 RAG 자료와 다른 점

첫째, 실패부터 시작합니다.

각 챕터는 잘 동작하는 코드가 아니라, 에러나 한계 상황에서 출발합니다. "왜 이게 안 되지?"를 먼저 경험하고, 그 이유를 찾고, 해결하는 순서입니다. 그 과정이 이해를 만듭니다.

둘째, 튜닝까지 다룹니다.

대부분의 RAG 자료는 검색 결과가 나오는 순간 멈춥니다. 이 책은 "왜 엉뚱한 문서를 가져오나", "왜 같은 뜻인데 못 찾나"까지 파고듭니다. 검색 품질 튜닝(CH08 하이브리드 검색), 질문 해석 개선(CH09 Query Rewrite), PDF·이미지 처리(CH10 Vision LLM), 그리고 이 모든 튜닝을 한 서비스로 엮어 내는 완성 에이전트(CH11)까지 포함되어 있습니다.

셋째, 이야기로 읽힙니다.

API 명세가 아니라 스토리입니다. 팀장의 지시에서 시작해서, 동료의 불만을 들으면서, ConnectHR이 한 단계씩 성장하는 이야기입니다. 비유와 상황으로 먼저 개념을 잡고, 그 다음에 코드로 들어갑니다.

이 책의 구조

챕터 하나는 상황 → 코드 → 개념 → 결과의 흐름으로 이어집니다. 현실에서 마주치는 문제가 먼저 등장하고, 그 문제를 푸는 코드가 뒤따르고, 코드가 왜 그렇게 생겼는지 개념으로 정리한 뒤, 실제 실행 결과로 닫습니다.

코드가 낯설다면 상황 설명과 결과 해석 부분을 먼저 따라가도 흐름이 이해됩니다. 코드는 그 뒤에 돌아와 다시 읽어도 늦지 않습니다.

이 책이 맞는 분

- Python 기초 문법은 알지만, LLM이나 RAG는 처음인 분
- 예제는 따라 해봤지만, 처음부터 끝까지 하나의 프로젝트를 만들어본 적 없는 분
- "이론은 알겠는데, 실제로 작동하는 걸 보고 싶다"는 분

마지막으로

이 책은 정답을 알려주지 않습니다.

에러를 만나고, 왜 그런지 고민하고, 고치는 과정을 함께 걸어갑니다. ConnectHR이 완성될 때쯤이면, 단순히 코드를 복붙한 게 아니라 "왜 이렇게 만들었는지"를 이해하게 됩니다.

그게 이 책이 하고 싶은 것입니다.

자, 이제 시작해보겠습니다.